字节级 BPE 分析与多语言抽样设计

Byte-Level BPE Analysis and Multilingual Sampling Design

Technical Research Report

摘要

本文通过源码与运行记录，跟踪 MinBPE 如何学习和应用合并规则。训练 abababab 时，第一轮得到四个连续的 ab 词元。第二轮统计到三个相邻位置对，从左往右合并时每个词元只能用一次，因此执行两次替换。另一个例子说明，编码新文本时按训练得到的规则优先级合并。在选定的八个普通文本输入上，MinBPE 包装器与 cl100k_base 逐个编号一致，解码均还原原文。验证程序的十七组行为检查全部通过。另在真实德语和西语语料上比较三种配额、三个种子。将分词器训练份额从 90:10 改为 75:25 后，二元语言模型在留出集上的双语等权字节困惑度从 8.4111 降至 8.2738（下降 1.63%），其中西语改善，德语略有退步。50:50 的均衡基线为 8.2709。

关键词：字节级 BPE；编码一致性；UTF-8；多语言抽样；可复现性。

1 研究问题与分析框架

本项目用三组证据分析分词器：跟踪固定版本 MinBPE 的合并操作，在八个指定输入上核对 `cl100k_base` 的编码，再用真实德语和西语文本检验训练配额如何影响一个小型语言模型在留出文本上的预测损失。

第一组证据解释 BPE 的局部操作。第二组将具体实现与参考编码逐项比较。第三组保持模型训练文本和测试文本固定，改变分词器学习规则时所见的语言比例。这样可以在相同文本单位上比较几种配额。

1.1 研究问题与可检验命题

问题	操作性检查	证据能够回答的范围
RQ1：BPE 训练与编码中的选择依据有何不同？	跟踪相邻对频率、实际替换次数和已学合并优先级；构造两种选择规则产生不同编号的输入。	定位重叠计数与不重叠替换的差别，并检查新文本编码是否遵循既有规则。
RQ2：具体编码包装器在什么范围内复现参考实现？	在固定编码、固定依赖和同一输入上比较完整 `token` ID 列表、字节拼接和文本往返。	确认所覆盖普通文本案例的一致性，识别正则边界、UTF-8 片段与字节编号映射的作用。
RQ3：改变分词器训练中的德语 / 西语配额，会怎样影响留出文本的预测成本？	在固定词表与分词器预算下比较三种配额；每组使用相同模型训练文本和测试文本。	报告逐语言及等权汇总的字节归一化结果。解释范围限于所测语料和模型。

对 RQ1，检验重点是可区分的行为命题：统计阶段允许相邻窗口共享位置，替换阶段按从左到右的不重叠配对消耗位置；训练时选择当前最高频相邻对，而编码时选择已学规则中优先级最高的可用合并。对 RQ2，判据采用精确编号相等与完整文本还原，而不是仅比较 `token` 总数。对 RQ3，各候选模型看到相同的预测任务。按原文 UTF-8 字节数归一化损失，可将不同分词方案的结果放在同一尺度上。

1.2 分析设计与证据来源

算法分析固定在 MinBPE 提交 `1acefe89412b20245db5a22d2a02001e547dc602`。上游文件保留原始实现、许可与哈希，项目中的跟踪和核对代码调用这些实现并保存中间状态。因此，可以将报告中的每个关键步骤追溯到具体函数、执行行和结构化结果，而不必依赖图形外观反推算法行为。

- 受控机制检查：训练微型词表，记录初始字节、每轮全部相邻对计数、所选规则、实际替换次数、词表内容与最终编号。将跟踪结果与 `BasicTokenizer` 的训练、编码及解码输出核对。
- 差分编码检查：分别初始化 MinBPE `GPT4Tokenizer` 与 tiktoken 的 `cl100k_base`，对英文、德语、西班牙语、中文、数字、换行、Emoji 和空输入执行同一组核对。输入范围及逐 `token` 字节内容保存在结果文件中。
- 多语言预测实验用同一分配器生成三组候选配额，在真实德语和西语文本上训练分词器及预测模型，再在留出文本上以相同的字节单位比较。各次运行的测试规模和原始结果可单独核对。

记录单位	具体含义	解释约束
相邻对频率 / 替换次数	前者计数所有相邻位置窗口，后者记录一次实际合并消耗的非重叠配对。	两个数值描述不同操作，存在重复元素时不能直接互换。
token ID / UTF-8 字节	ID 是编码词表中的索引，字节是该索引对应的原始内容。	ID 数值本身不表示字符语义；一个 token 的字节可以不是完整字符。
Unicode 码点 / token 数	前者作为一致清洗规则下的文本预算单位，后者作为候选编码的输出长度。	语言比例以输入文本计量，避免因候选分词器改变而同时改变输入预算。
检查项 / 输入案例	检查项可包含多条断言；输入案例是一次具体的文本及其编码记录。	17 项行为检查与 8 类普通文本是不同计数，不视为独立数据集数量。

合并轨迹、八个编码对照及分组检查分别保存在 `results/bpe_walkthrough.json`、`results/gpt4_check.json` 与 `results/verification.json`。`results/language_mix.json` 记录假设库存的配额计算，`results/quota_pilot.json` 记录真实文本上的多语言预测实验。源码审计附录列出实现行号和解释。

1.3 主要观察及机制解释

输入 abababab 在第一轮后变成四个 ab 词元，按从左到右编号为 1 至 4。第二轮统计时，第 1、2 个，第 2、3 个和第 3、4 个都构成相同的相邻对，共三个候选位置。替换时先合并第 1、2 个，第 2 个已经用过，接着合并第 3、4 个，得到两个 abab 词元。频次 3 计的是候选位置，替换次数 2 计的是本轮实际执行的合并。

合并优先级反例进一步把训练与推断区别转化为可检查的输出差异。同一新输入上，若错误地优先合并当前更高频的相邻对，会得到不同的编号序列。已有规则的先后顺序因而是编码规范的一部分，而不只是训练过程的记录。仅在新文本上重新统计频率，不能替代已训练的合并表。

编码对照中，八个给定输入的完整编号与参考编码逐项一致，拼接各 token 的字节后也能还原原文。结果章节列出全部输入，包括空字符串。检查还展示了两个实现细节：原始字节值与单字节 token ID 存在重排关系；某些 token 只含一个 UTF-8 字符的部分字节。

在留出德语 / 西语文本上，将分词器训练配额由 90:10 改为 75:25 后，小型二元模型的双语等权字节困惑度下降 1.632%。分语言看，西语改善，德语略有退步。均衡配额 50:50 的双语结果与 75:25 很接近。各语言数值、配对种子结果和文档抽样区间见第三节。

1.4 复现与推断边界

现有算法轨迹和编码对照是确定性计算，复现对象由输入、固定源码、依赖版本和参考编码共同定义。保存中间序列与原始字节，使差异可以定位到具体步骤；保留完整结果而不只保存汇总数字，使后续扩展能够重复既有检查并记录新增覆盖范围。AI 辅助开发和审查记录与上游归属单独保留，以说明材料的产生过程。

编码核验只覆盖所列普通文本和配置。多语言实验使用一个小型预测模型，结论取决于数据来源、训练预算及基线。要评价问答、翻译或大型模型的生成能力，需要独立的目标任务与对应指标。

2 编码验证结果与机制证据

以下结果来自仓库保留的实际运行记录，可用 `code/verify.py` 与 results 中的原始编号、字节和检查项核对。受控输入用于分析合并机制；普通文本用于比较两个编码实现。所有结果均针对所记录的配置与输入范围。

环境项	实际记录
Python	3.12.14
regex / tiktoken	2026.9.29 / 0.14.0
MinBPE	`1acefe89412b20245db5a22d2a02001e547dc602`
随机性	BPE 示例与对照均为确定性计算，无随机种子

2.1 三轮合并与新文本编码

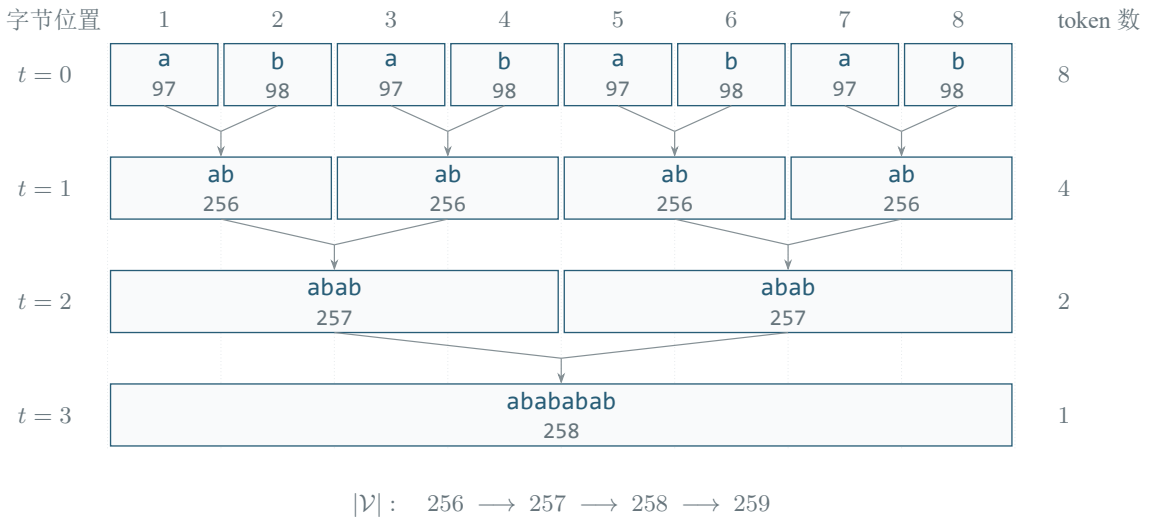


图 1 受控输入 abababab 的真实 BPE 合并轨迹。横向位置与块宽表示覆盖的原始字节；每轮把已有相邻 `token` 合成新 `token`。图中 `token` 数是当前文本的长度，词表大小则是可用编号的总数，两者不同。数据来源：`results/bpe_walkthrough.json`。

轮次	选中相邻对	统计次数	实际替换	合并后的 ID
1	[97, 98]	4	4	[256, 256, 256, 256]
2	[256, 256]	3	2	[257, 257]
3	[257, 257]	1	1	[258]

第二轮开始时四个词元均为 ab（编号 256）。三个候选窗口分别覆盖位置 (1,2)、(2,3)、(3,4)。按从左到右的规则，替换 (1,2) 后直接到位置 3，再替换 (3,4)。三轮结束后，训练文本 abababab 编为 [258]；新文本 ababab 编为 [257, 256]，分别对应 abab 与 ab。两段文本均能解码还原。

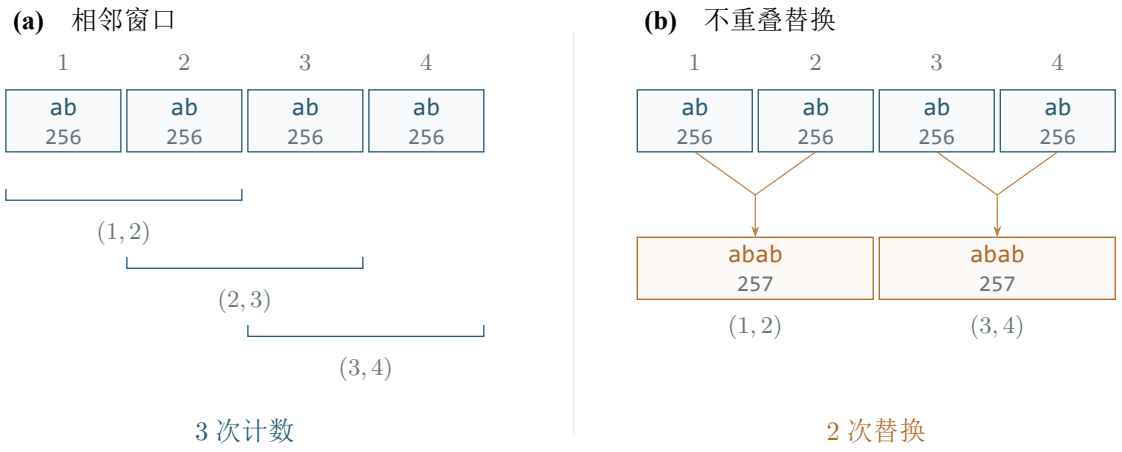


图 2 同一序列的两个视角：`get_stats` 检查所有相邻窗口，共计 3 个；`merge` 从左到右只替换不重叠的相邻对，共 2 次。因此日志中的出现次数不能直接当成实际替换次数。数据来源：上述实测记录的第 2 轮。

2.2 一个可以证伪错误理解的反例

用 ab1ab2ab3ab4bcbcbc 训练两次合并后，规则为 ab→256、bc→257。对新文本 abcbcbcbc，ab 只出现 1 次，bc 出现 4 次；正确编码仍先执行编号更小的 ab 规则。

正确：`[256, 99, 257, 257, 257]`
错误地先按新文本频率合并 `bc`：`[97, 257, 257, 257, 257]`

这说明 `encode` 中虽然也调用 `get_stats`，返回的出现次数却不是本轮选取依据；该函数还用于枚举当前有哪些相邻对。选择规则由 `self.merges` 中的已有优先级决定。

2.3 与 cl100k_base 的普通文本对照

类别	输入（换行以转义表示）	token 数	编码 / 还原
英文	'Hello, world!'	4	一致 / 成功
德语	'Füße, Straße und Häuser.'	10	一致 / 成功
西班牙语	'¡Hola! ¿Cómo estás? El niño come piña.'	15	一致 / 成功
中文	' 你好，世界！'	7	一致 / 成功
数字	'1234567890'	4	一致 / 成功
换行	'line one\n\nline two\n'	6	一致 / 成功
Emoji	'U+1F642U+1F680'	5	一致 / 成功
空字符串	''	0	一致 / 成功

PDF 中 Emoji 用 Unicode 码点名称显示；真实字符、完整 ID 与字节数据保存在 `results/gpt4_check.json` 和对应中文 TXT 中。

具体输入	真实 token ID
Hello, world!	[9906, 11, 1917, 0]
你好，世界！	[57668, 53901, 3922, 3574, 244, 98220, 6447]
1234567890	[4513, 10961, 16474, 15]

中文例子中的“世”对应的 UTF-8 字节被拆在两个 token 中：ID 3574 对应 e4 b8，ID 244 对应 96。这两个 token 单独都不是完整字符；拼回字节后 e4 b8 96 才是“世”。因此，不应把每个 token 单独解码后出现的替换符当成分词错误。

数字 1234567890 先被正则分成 123、456、789、0，再在各块内部编码。字节编号也与 `BasicTokenizer` 不同：原始字节 97（a）对应 `cl100k_base` 单字节 token ID 64；空格字节 32 对应 ID 220。这就是 `GPT4Tokenizer` 需要 `byte_shuffle` 的原因。

2.4 检查范围与运行方法

`code/verify.py` 中的 17 组检查全部通过，覆盖重叠合并、尾部剩余、空输入、Unicode 完整往返、规则优先级、普通文本编码对照、编号重排和 `GPT4Tokenizer` 不可训练等行为。有限样例不能证明所有可能文本均正确，也未测试特殊 token 的完整往返。

```
python -m pip install -r requirements.txt
python code/verify.py
python code/language_mix.py
```

当前电脑也可以执行项目根目录的 `run_examples.ps1`。无需 GPU 或模型 API；详细中文步骤见“使用说明.txt”。官方源文件、MIT 许可证、提交号及文件哈希都随项目保留。

3 多语言配额、留出集预测与后续设计

同样多的训练文本，可以按不同比例分给德语和西语。在本章的小规模实验中，候选配额通过指数平滑生成，再用真实语料训练分词器，用独立文本检验预测成本。最后介绍一个扩大语料与词表的后续设计。

3.1 先明确：调的是分词器比例，不是大模型比例

BPE 训练是在决定“哪些相邻片段值得合并、有限的词表要记住哪些常见片段”。如果某种语言在训练材料中占比更高，它的片段往往更容易获得合并机会。因此，语言比例会影响两种语言的切分长度。词表也存在跨语言共享片段，所以不能简单认定“德语占 70% 的语料，就必然占 70% 的词表”。

要决定的比例	它影响什么	本项目如何处理
`Tokenizer` 训练语料比例	BPE 合并规则与共享词表	本项目主要研究对象
LLM 预训练语料比例	模型学习各语言的机会及能力	若做下游对照，应固定它，避免混淆
实际使用需求比例	系统服务哪些语言与任务	用于定义评价权重，不直接等同于前两者

例如，用户请求中有 70% 德语，不代表分词器必须用 70% 德语训练。德语是否已经能被高效切分、西语是否被切得过碎、语料是否覆盖真实业务，都需要一起考虑。反过来，分词器给两种语言相同训练份额，也不能保证大模型获得相同语言能力。

3.2 三篇论文提供了什么证据

[R1] Zhang 等（2022）直接研究 tokenizer 训练中的语言不平衡。他们固定模型训练设置，改变分词器语料比例；在其机器翻译实验中，更均衡的比例往往较好，但性能对比例失衡也比直觉预期更稳健。他们强调，tokenizer 抽样与模型训练抽样需要分别研究。主要实验采用 SentencePiece Unigram，并以 BPE 做消融。研究是英语中心、最多涉及八种语言，未直接测试德语 / 西语组合，因此不能把结论写成“德西 1:1 已被证明最优”。

> [R1] Zhang et al. (2022). How Robust is Neural Machine Translation to Language Imbalance in Multilingual `Tokenizer` Training? 重点：§3.1、§3.4、§4、§6。
> https://arxiv.org/html/2204.14268v2

[R2] Rust 等（2021）比较多语言与单语言模型，发现语言在词表中是否得到充分表示，与下游表现有关。他们使用 fertility（每个词平均切成多少个子词）和被拆分词的比例描述切分程度。这支持“逐语言检查是否过度切分”，但不支持“`token` 越少，模型必然越好”，也没有直接给出德语 / 西语应采用的采样比例。

> [R2] Rust et al. (2021). How Good is Your `Tokenizer`? On the Monolingual Performance of Multilingual Language Models. 重点：§4.2、§4.3 与相关性分析。
> https://aclanthology.org/2021.acl-long.243/

[R3] Chung 等（2023）的 UniMax 尽量均匀分配语言预算，同时限制小语种语料重复次数。论文还为不同采样策略分别训练词表，并以字符数衡量各语言语料规模。可借鉴的是“均衡、避免过度重复、先定义计量单位”。它研究的是多语言预训练整体设置，其性能提升不能全部归因于 tokenizer 比例，也不能直接当作 byte-level BPE 的最佳配比结论。

> [R3] Chung et al. (2023). UniMax: Fairer and more Effective Language Sampling for Large-Scale Multilingual Pretraining.

重点：§3、§3.1、§4.2。
https://arxiv.org/html/2304.09151v1

证据层次	本文采用的内容	不能越过的边界
文献直接支持	在原论文的语言、模型和任务范围内，分词质量与表现有关；抽样阶段需要区分	不推广成所有 LLM、所有语言对的必然规律
文献启发的设计选择	参考平滑抽样、字符计量、重复限制与逐语言切分诊断	分别在本次留出测试与后续规模实验中评价
本报告自己的建议	候选配比、5 百万字符、8,192 词表、三种子与 5% 门槛	是实验设计选择，不是论文给出的最优配置

3.3 收集语料时，比例前面还有三个条件

- 内容质量：先检查语言标签，去掉乱码、模板、广告、重复或近重复文档。误标为西语的英文网页，不能算成有效西语训练材料。
- 领域覆盖：两种语言分别覆盖目标任务需要的领域，例如通用文本、技术说明与对话。若一边全是新闻、另一边全是代码，比较出的差异同时包含语言与领域差异。
- 计量单位：本文将比例定义为清洗后 Unicode 字符数占比，并固定正规化方式；不能混用文档数、字节数、词数和 `token` 数。

具体可统一采用 NFC 正规化，并按 Unicode 码点计数，空格和标点也计入；训练、验证与测试使用完全一致的规则。这是一个可复现的工程口径，不表示字符数能完整衡量语义信息。文档长短不同，所以“各取 100 篇”不等于材料数量相同；UTF-8 中带重音字符可能占多个字节，所以字节占比也不等于字符占比。不要用正在比较的 tokenizer 输出 `token` 数反过来定义输入份额，否则比较口径会随候选方案改变。

德语与西语共享不少字母和标点，但仍应保留并检查各自常见的特殊字符、词形变化与长词。建议人工查看如德语复合词，以及西语带重音或变位的词，确认常见内容没有异常碎裂。这些是诊断样例，不应仅靠几个手选单词决定整个比例。

3.4 用平滑抽样生成候选比例

设 n_l 是语言 l 清洗后可用的字符数。可先用下面的指数平滑规则产生候选份额 q_l。α 是需要尝试的参数，不是从论文复制后就永远适用的常数；这里仅考虑 n_l 大于零的语言。

$$q_l = \frac{n_l^{\alpha}}{\sum_j n_j^{\alpha}}, \qquad 0 \le \alpha \le 1. \tag{1}$$

α	直观含义	假设原始德语: 西语 =9:1 时
1	保持清洗后的原始份额	9:1，即 90%:10%
0.5	减小大语种的优势	$\sqrt{9}$:$\sqrt{1}$=3:1，即 75%:25%
0	在语料非空的语言间均匀分配	1:1，即 50%:50%

附带的 `code/language_mix.py` 已实际计算这个数学例子：假设德语有 900 万字符、西语有 100 万字符，训练预算为 100 万字符，α=0、0.5、1 对应的德语 / 西语配额分别为 50 万 / 50 万、75 万 / 25 万、90 万

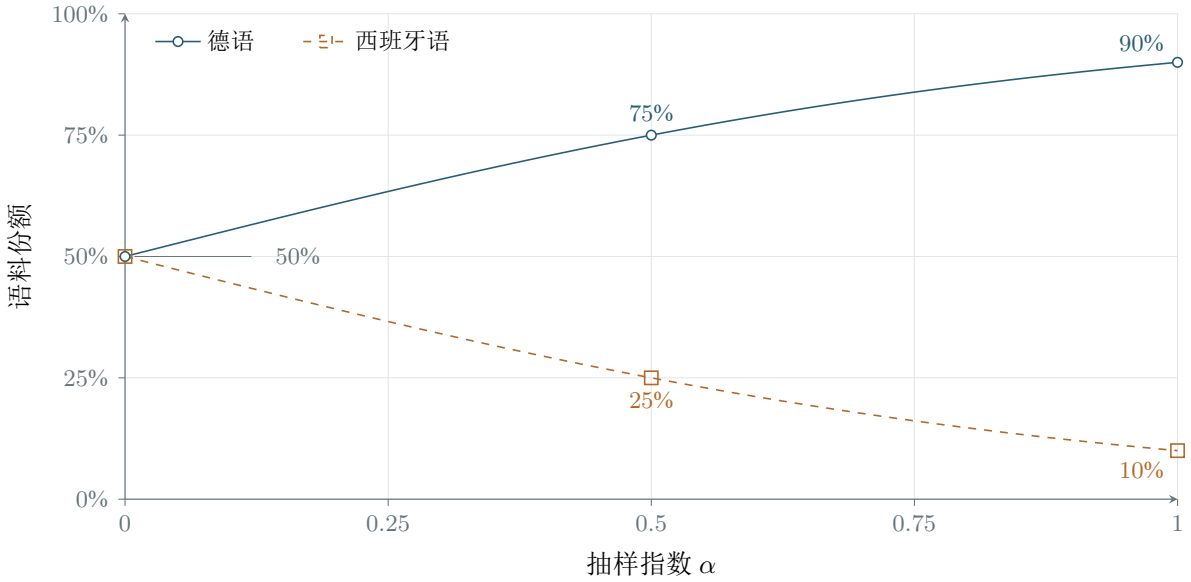


图 3 假设清洗后德语与西语的库存字符数为 9:1，指数平滑参数 α 如何改变训练份额。曲线由公式精确计算，标记点与 `language_mix.py` 的配额结果一致。这是数学情景，不是语料采集结果或模型性能曲线，也不能据此确定最佳 α。完整点数据见 `figures/language_sampling.csv`。

/ 10 万。配额总和、份额总和、平方根平滑与零库存边界共 4 项检查通过。输入数量是假设值；程序没有训练或评估德语 / 西语分词器，完整输出在 `results/language_mix.json`。

表中的 9:1 只是数学例子，不是本次收集到的真实语料统计。指数越小，分配越均匀。这个规则帮助系统地提出候选，但不能表达所有业务偏好；还可以直接比较 30:70、50:50、70:30 等比例。若预计主要服务德语，应在报告中事先说明评价权重，同时保留西语的最低质量要求，而不是在看到结果后挑一个对自己有利的权重。

提高某语言的相对份额不一定需要重复文本：可以减少另一语言的抽样量。扩大规模时建议优先不放回抽样，即同一文档最多使用一次。若某个候选比例需要的唯一语料超过库存，应补充语料、对所有候选统一降低总预算，或明确标记该候选不可行；不能静默复制少量文本来凑比例。若另做带重复上限的方案，应记录上限、实际重复量及与无重复方案的差别。这是借鉴 UniMax 的控制思想，而不是声称复现其全部算法。

3.5 德语 / 西语留出集实验

实验只调整分词器学习合并规则时的德语和西语份额。每种分词器对应训练一个二元语言模型：已知前一个 `token`，它估计下一个 `token` 或句末的概率。各模型读取相同的原始训练句，接受相同的留出句测试。

项目	九次训练共同遵循的设置
训练文本	Universal Dependencies 2.15 的 German GSD 与 Spanish GSD 官方训练集。每语选取 1,500 个不同的 NFC 句子组成固定训练池，排除与测试集完全相同的句子。
测试文本	外部 German PUD 与 Spanish PUD。两种语言各 1,000 句，对应相同的 397 份源文档。平行文本让两种语言的测试主题相匹配。
配额与预算	继续采用假设库存 9:1 导出的三种德语 / 西语份额：50:50、75:25、90:10。分词器每次训练使用总计 50,000 个 Unicode 码点，按整句抽样。
分词器与随机性	每种份额使用相同的 512 项字节级 BPE 词表规模，分别取抽样种子 11、29、47。相同种子用于每种配额，以便配对比较。
预测模型	各分词器将固定德西训练池编码后，分别训练一个双语二元模型。预测概率采用加 0.1 平滑，逐句计入起点和句末。

配额只作用于 BPE 训练的 50,000 个码点。二元模型始终读取同一批德语和西语句子；这样，语言模型能接触的训练内容就不会随分词器配额而改变。GSD 与 PUD 是不同来源的语料，即使排除了完全相同的句子，测试中的文体差异仍可能影响结果。

数据由 Universal Dependencies 发布。训练与测试语料的版本、下载地址、校验值及许可记录见实验代码与结果文件。下面的地址可查看本次使用的树库版本。

Universal Dependencies 2.15 · German GSD
https://github.com/UniversalDependencies/UD_German-GSD/tree/r2.15

Universal Dependencies 2.15 · Spanish GSD
https://github.com/UniversalDependencies/UD_Spanish-GSD/tree/r2.15

Universal Dependencies 2.15 · German PUD
https://github.com/UniversalDependencies/UD_German-PUD/tree/r2.15

Universal Dependencies 2.15 · Spanish PUD
https://github.com/UniversalDependencies/UD_Spanish-PUD/tree/r2.15

3.6 如何在不同词表之间比较困惑度

同一句话可能被两个分词器切成不同数量的 token，因此按 token 平均的损失没有共同的分母。这里先算每个模型给完整原句分配的概率，再按所有测试句共有的原文 UTF-8 字节数归一化。字节困惑度越低，表示模型平均每字节给实际出现的文本分配了更高的概率。

$$L_l = -\sum_{s \in S_l} \log_2 P(s), \qquad \mathrm{BPB}_l = \frac{L_l}{B_l}, \qquad \mathrm{PPL}_{\mathrm{byte},l} = 2^{\mathrm{BPB}_l}. \tag{2}$$

S 表示某一语言的测试句集合，B 是这些句子的 UTF-8 字节总数。为了得到原句的概率，程序将所有能拼出原句的 token 路径概率相加，并计入句末概率。只给 BPE 默认切分打分时会漏掉其他路径；这项分数另作诊断。

3.7 实测结果：平滑配额改变了两种语言的预测成本

验证前指定的主比较，是把假设库存 9:1 对应的 90:10 改为平方根平滑后的 75:25。另外列出 50:50 均衡配额，以便读者判断结论如何随基线变化。测试集包含 127,846 个德语字节和 125,105 个西语字节。

德语 / 西语训练份额	德语字节困惑度	西语字节困惑度	双语等权困惑度
50:50（均衡）	8.8404	7.7380	8.2709
75:25（平滑）	8.6282	7.9340	8.2738
90:10（按库存比例）	8.5383	8.2858	8.4111

表中数值越低越好。每种语言先对三个种子的每字节比特数取平均。汇总列再对两种语言的每字节比特数等权平均，最后取 2 的相应次幂，因此等于两语困惑度的几何平均数。

将西语份额从 10% 提高到 25% 后，西语困惑度下降 4.246%，德语上升 1.053%，双语等权困惑度从 8.4111 降至 8.2738，下降 1.632%。三个种子下的双语降幅分别为 1.189%、1.951%、1.756%。50:50 的双语结果为 8.2709，75:25 比它高约 0.036%，两者的排序会随种子改变。

为估计测试文档取样带来的波动，将 397 个对齐文档有放回地抽取 4,000 次，每次对两种语言、所有种子和两种配额采用同一组文档。75:25 相对 90:10 的双语困惑度变化为 −1.632%，95% 百分位区间为 −1.775% 至 −1.491%。这个区间以已经训练的模型为条件，只描述本测试集的文档取样波动。

在这组数据上，相对 90:10，平滑配额带来的西语收益超过德语损失，双语平均预测成本下降。是否采用该配额还取决于对两种语言的权重。实验测量的是小型二元模型预测留出文本的能力。问答、分类或翻译的准确率需要在有标注的目标任务上另行测量。

复现时先运行以下命令。首条命令获取固定版本语料并校验哈希，生成逐次训练结果和逐文档分数。第二条命令由同一批文档分数计算条件区间。

```
python code/quota_pilot.py
python code/quota_uncertainty.py
```

训练计划、实际字符数、模型及样本摘要在 `results/quota_pilot.json`。逐文档的字节数和预测损失在 `results/quota_pilot_documents.csv`，区间估计在 `results/quota_uncertainty.json`。

3.8 扩大规模的实验设计（后续工作）

下表给出后续实验拟采用的设置。它把分词器训练预算扩大到 500 万字符，再按预先写下的指标筛选候选。所有候选应使用相同的总预算、词表大小与分词实现。

项目	预先固定的设置
数据划分	按完整文档或来源先去重，再划分训练 / 验证 / 测试；三者不共享重复或近重复内容
`Tokenizer` 家族	同一种 byte-level BPE、同一预切分规则、NFC 规则与特殊 `token` 策略
训练预算	每个候选共 5,000,000 个字符；不足时统一降低所有候选的预算
词表大小	8,192 个普通 `token`，包含 256 个基础字节；特殊 `token` 如需使用则另外固定
候选德语: 西语份额	10:90、30:70、50:50、70:30、90:10；另加入实际库存的 α=0.5 候选，重复项合并
验证 / 测试	两种语言分别留出 200,000 字符验证集和 200,000 字符最终测试集；不足则统一缩小并报告
抽样重复	每个候选用 3 个预先固定的随机种子独立抽样；记录种子、语料来源、哈希与实际份额

先按语言与领域分层，再按字符预算抽取完整文档，避免一个比例恰好抽到更多简单文本。完整文档长度可能让最终份额偏离目标，应设置小的预算容差并报告实际字符数与份额。如果必须截取片段，应先将文件解码成 Unicode 文本，再按完整文本边界截取；不能在原始 UTF-8 字节流中直接切到指定长度，否则可能把一个字符切坏。公平比较要求固定输入字符预算，而不是固定候选 tokenizer 各自产生的 `token` 数。不同候选的输出 `token` 数本来就是要测量的结果。

验证集用于比较候选、选比例；测试集在方案确定后才用于最终报告。即使所有数据都来自公开网页，也不能把训练集上的压缩效果写成泛化效果。随机种子的重复用于观察语料抽样带来的波动，不代表训练了三个大语言模型。

3.9 扩大规模时如何选择候选

$$T_l = \frac{\#\,\text{tokens}_l}{\#\,\text{characters}_l}. \tag{3}$$

T_l 表示平均每个字符需要多少 `token`。在同一语言、同一份验证文本上，T_l 较低说明切分更紧凑。例：同一段 1,000 字符的文本被候选 A 切为 400 tokens，候选 B 切为 500 tokens，则 T 分别是 0.40 与 0.50。这只是指标计算例子，不是实际测量。具体计算时，逐个编码正规化后的非空文档，分子累加普通文本 `token` 数，分母累加这些相同文本的 Unicode 字符数，包含空格与标点，不额外插入特殊 `token`。不要先把文档拼接得可跨文档合并。本文使用总数之比，与逐句比率再平均不同，应在实现与报告中保持一致。

指标 / 检查	作用	解释边界
逐语言 tokens / character	比较同一语言在各候选下的序列长度	跨语言不能直接当成能力或公平分数
Fertility：每词平均子词数	观察词被拆分的程度；需固定词边界规则	德语长复合词与西语词形不同，不能要求两语数值相等
长文 `token` 长度的 P95	观察较长输入的上下文压力	需固定文档集合；P95 是 95% 文档不超过的长度
编码再解码一致性	确认规范化后的文本可完整还原	完整字节覆盖通常无 UNK，但不等于切分高效
常见词、专名、数字和混合语言样例	发现平均指标掩盖的局部异常	用于诊断，不替代独立验证集

Fertility 只作为辅助指标。为了让实现明确，可以先按空白和标点切出词，并在所有候选上使用同一规

则，对词分别分词，计算每词 token 数；应说明这是一种操作性定义，与整段文本编码可能不同。如果改用语言学词边界标注，则两种语言分别使用固定标准，并注明来源。最有意义的比较是“同一语言在新方案相对基线改善多少”，而不是直接比较德语和西语谁的 fertility 更低。

若两种语言同等重要，可以先以 50:50 为基线，再比较各语言 T 相对基线的变化。一个明确的选择规则是：先排除任一语言相对基线恶化超过预设容忍度的候选，再在剩余候选中选加权平均相对长度最小者。容忍度和权重属于项目要求，必须在看结果之前写下；例如先导阶段可暂设每语不恶化超过 5%，两语各占一半权重，再做敏感性检查。这里的 5% 是提议的工程门槛，不是论文结论。

$$\begin{aligned} R_l(q) &= \frac{T_l(q)}{T_l(0.5)}, \\ J(q) &= w_{\text{de}} R_{\text{de}}(q) + w_{\text{es}} R_{\text{es}}(q), \qquad w_{\text{de}} + w_{\text{es}} = 1. \end{aligned} \tag{4}$$

报告每个候选的三次抽样均值和范围。若差异小于抽样波动，不应宣称某个比例明显更优；可保留几个折中候选。tokenizer 筛选完成后，若预算允许，再用相同模型架构、固定 LM 语言采样分布和预先约定的训练计算预算，对少数候选做下游验证。不同词表的每 token 困惑度不能直接横比，可使用同一原文上的按字节或字符归一化损失，并辅以德语 / 西语目标任务评价。

3.10 适用范围

实际应用可以按目标语言的使用需求预设权重，再用独立数据确认任一语言的损失是否超出可接受范围。业务语言分布、领域或模型变化时，需要重新检验这项选择。

字符数衡量输入预算，token 数衡量序列长度，预测损失衡量指定模型给真实留出文本分配了多大概率。目标任务的答对比例还需要标注答案及判分规则。这些指标回答不同问题。

A 算法基础与源码审计补充材料

本节分析 BPE 的规则学习与编码机制，并将每个关键步骤对应到固定版本 MinBPE 的 Python 函数及代码行号。通过可手算的输入观察相邻对统计、合并优先级和 UTF-8 字节处理，再检查 `cl100k_base` 编码包装器的实现边界。

BPE 的核心做法是：先把文字拆成很小的单位，反复寻找最常一起出现的相邻两块，把它们合成一个新单位。训练结束后，这些合并规则固定下来。之后处理新文字时，分词器照着已有规则合并，不会重新学习一套词表。MinBPE 采用字节级 BPE，最小单位是 UTF-8 字节，而不是汉字或完整英文单词。

名词	先这样理解
`token`	模型处理文字的一个单位；可能是单个字节、一个字的一部分、几个字母、单词或其他片段，并不等于“单词”。
`token` ID	这个单位的整数编号。编号是查表用的标签，数值大小本身不表示词义。
字节（byte）	计算机保存数据的基本单位之一，一个字节的数值在 0 到 255 之间。
UTF-8	把文字转换成字节序列的一种规则。英文 a 只需一个字节，汉字通常需要多个字节。
`vocab`（词表）	在本仓库中主要指“`token` ID → 对应字节串”的表，用于恢复文本。
`merges`（合并表）	“两个相邻 `token` 的编号 → 新 `token` 编号”的表。
`train` / `encode` / `decode`	分别是学习合并规则、将文字变成编号、将编号恢复为文字。不要把三者混为一谈。

A.1 先手算一遍：ababababab 如何被压缩成一个 `token`

下面是教学手算，不是某个真实 GPT-4 输出。为便于看清过程，只用英文 a 和 b，并按 `BasicTokenizer` 的实现设定 `vocab_size`=259。初始 256 个 `token` 对应所有可能的单字节；a 的字节值是 97，b 的字节值是 98。目标词表大小为 259，所以要学习 259−256=3 条合并规则。

阶段	当前序列	统计与选择	合并结果
开始	[97,98,97,98,97,98,97,98]	(97,98) 出现 4 次；(98,97) 出现 3 次。选择 (97,98)，新编号 256。	[256,256,256,256]
第 2 轮	[256,256,256,256]	相邻窗口中的 (256,256) 共 3 次；把它定为新编号 257。	[257,257]
第 3 轮	[257,257]	(257,257) 出现 1 次；把它定为新编号 258。	[258]

第 2 轮最容易看错：四个 256 之间有三个相邻窗口，所以统计次数是 3；但真正替换时，一个位置不能被两个合并同时使用。程序从左向右先合并第 1、2 个，再合并第 3、4 个，因此只发生 2 次替换。相邻对的统计允许重叠，实际替换采用不重叠配对；二者不必相等。

新 `token` ID	合并规则	对应的实际字节内容
256	(97,98) → 256	ab
257	(256,256) → 257	abab
258	(257,257) → 258	abababab

训练后，词表仍保留原来的 256 个单字节 `token`，并增加这 3 个新 `token`。不是把 a、b 删除了。输入另

一个字符串 abababab 时，按已有规则可先得到 [256,256,256]，再得到 [257,256]；最终分别代表 abab 和 ab。训练没有学过 (257,256) 的合并规则，所以不能继续把它合成一个 token。

下面是附带 code/bpe_walkthrough.py 中的核心调用方式。完整脚本已配置 vendor 源码的导入路径，直接运行该脚本即可。这里只训练一个很小的 BasicTokenizer；编号由该微型词表决定。手算已与实际程序结果核对，完整运行记录见后文。

```
from minbpe import BasicTokenizer

tokenizer = BasicTokenizer()
tokenizer.train("abababab", vocab_size=259, verbose=True)
print(tokenizer.encode("abababab"))  # 手算预期：[258]
print(tokenizer.encode("ababab"))    # 手算预期：[257, 256]
print(tokenizer.decode([257, 256]))  # 手算预期：ababab
```

A.1.1 再看中文：“你好”为什么从 6 个字节开始

英文例子中，一个字母恰好只占一个字节；中文不能照搬这种对应关系。Python 中“你好”有两个 Unicode 字符，却会被 UTF-8 编码成六个字节。

文字	UTF-8 字节值	字节数
你	228, 189, 160	3
好	229, 165, 189	3
你好	228, 189, 160, 229, 165, 189	6

只用 abababab 训练的微型分词器没有学过这些中文片段的合并，所以“你好”会保留为 6 个初始 token。解码时把这些字节完整接起来，再按 UTF-8 还原，仍能得到“你好”。有更多中文训练材料的分词器可以学到不同的合并，因此不能据此断言所有模型都把“你好”切成 6 个 token。实际程序已核对这组字节和完整往返。

A.1.2 Python 语法与实现约定

写法	本项目中的意思
self	当前这个分词器对象。self.merges 表示这个对象保存的合并表。
class A(B)	定义一种 A 对象，它继承 B 已有的功能；A 还可以补充或改写功能。
__init__ / super().__init__()	创建对象时执行的初始化方法；super() 用来调用父类版本，先建立公共状态。
字典 d[key] 与 d.get(key, default)	前者直接查一个键；后者在键不存在时返回 default。这里常用默认值 0 或正无穷。
zip(ids, ids[1:])	把原列表与“去掉第一个元素后的列表”并排配对，得到每一对相邻编号。
max(stats, key=stats.get)	遍历字典里的键，按各键对应的统计次数比较，选次数最大的那一对。不是选数值最大的 token ID。
lambda p: ...	临时写一个短函数；这里规定比较相邻对 p 时应该看它的合并顺序。
min(..., key=...)	按 key 指定的标准找最小项。编码时用它选最早学到、优先级最高的可用合并。

写法	本项目中的意思
bytes([97,98]) 与 [97,98]	前者是字节串 b'ab'；后者是整数列表。内容可以对应，但它们是不同类型。
列表推导式 [f(x) for x in xs]	依次对 xs 中的每个元素执行 f(x)，收集为新列表。
append 与 extend	append 把一个对象加到末尾；extend 把另一个列表中的各个元素依次接到末尾。
return、break、continue	分别是返回函数结果、结束当前循环、跳过本轮并进入下一轮。

理解下面四个文件的分工即可：base.py 提供公共工具；basic.py 展示最简训练和编码；regex.py 在它的思路上增加正则预切分与特殊 token；gpt4.py 读取已有的 cl100k_base 规则，并处理其编号细节。代码段中的空行和英文说明不执行；配注重点逐一解释每条实际执行语句。所有行号均按本报告固定的 MinBPE 提交。

A.2 base.py：get_stats 统计相邻对，13–22 行

minbpe/base.py，第 13–22 行（仅列执行语句）

行号	原代码	逐行解释
13	`def get_stats(ids, counts=None):`	定义统计函数。ids 是整数列表；counts 可传入已有统计表，默认不传。
19	`    counts = {} if counts is None else counts`	没传 counts 就新建空字典；传了就继续使用同一个字典，保留已有计数。
20	`    for pair in zip(ids, ids[1:]): # iterate consecutive elements`	ids[1:] 从第 2 个元素开始；zip 将它与原列表配成相邻对，循环逐对处理。
21	`        counts[pair] = counts.get(pair, 0) + 1`	读出 pair 原有次数；不存在时按 0 处理，再加 1 并存回字典。
22	`    return counts`	返回统计字典。传入已有字典时，原字典也已经被直接更新。

例如 ids=[97,98,97]：zip 的结果是 (97,98)、(98,97)。对 [256,256,256,256]，结果是三个相同的 (256,256)，因此计数为 3。这里没有做任何合并，也没有决定新 token 编号。它只负责回答“每一种相邻对出现了多少次”。

A.2.1 base.py：merge 从左向右替换一类相邻对，25–41 行

minbpe/base.py，第 25–41 行（仅列执行语句）

行号	原代码	逐行解释
25	`def merge(ids, pair, idx):`	定义替换函数：ids 是原序列，pair 是要合并的两个编号，idx 是合并后的新编号。
31	`    newids = []`	建立空列表，用来收集合并后的结果。
32	`    i = 0`	从原序列的第 0 个位置开始检查。Python 下标从 0 开始。
33	`    while i < len(ids):`	只要还没走到原序列末尾，就继续处理。
35	`        if ids[i] == pair[0] and i < len(ids) - 1 and ids[i+1] == pair[1]:`	检查当前编号、右侧位置是否存在、右侧编号是否匹配。and 从左向右短路求值，边界检查通过后才访问 ids[i+1]。
36	`            newids.append(idx)`	匹配成功，把新 token 编号追加到结果。

行号	原代码	逐行解释
37	`i += 2`	原来的两个位置都已使用，指针向右走 2 格，避免重叠替换。
38	`else:`	如果相邻对不匹配，进入此分支。
39	`newids.append(ids[i])`	把当前这个原编号原样保留到结果中。
40	`i += 1`	只处理了一个位置，因此指针向右走 1 格。
41	`return newids`	返回新列表。函数没有直接改写传入的原列表。

这个函数不统计频次，也不比较不同规则的优先级；它只执行调用者已经选好的那条规则。训练和编码都会使用它，但“如何选 `pair`”由外层代码决定。函数内使用新列表，所以外层通常写 `ids=merge(...)`，让 `ids` 指向新的结果。

A.3 `basic.py`：创建最简单的分词器，15–18 行

`minbpe/basic.py`，第 15–18 行（仅列执行语句）

行号	原代码	逐行解释
15	`class BasicTokenizer(Tokenizer):`	定义 `BasicTokenizer`，它继承公共 `Tokenizer` 类。
17	`def __init__(self):`	定义创建该对象时调用的初始化方法。
18	`super().__init__()`	执行父类初始化，建立空合并表、初始词表等公共状态。

父类的初始词表含 256 个单字节 `token`。`BasicTokenizer` 不做正则预切分，也不专门识别特殊 `token`；整个输入的字节序列直接进入 BPE。因此它适合先理解核心算法，但不能仅凭它声称已经复现 GPT-4 分词。

A.3.1 `basic.py`：`train` 学习合并规则，20–49 行

`minbpe/basic.py`，第 20–49 行（仅列执行语句）

行号	原代码	逐行解释
20	`def train(self, text, vocab_size, verbose=False):`	定义训练方法。text 是训练文本；`vocab_size` 是目标词表大小；`verbose` 控制是否打印过程。
21	`assert vocab_size >= 256`	要求词表至少容纳 256 个初始字节 `token`，否则断言失败。
22	`num_merges = vocab_size - 256`	每次合并新增一个 `token`，所以训练轮数等于目标大小减去 256。
25	`text_bytes = text.encode("utf-8") # raw bytes`	按 UTF-8 规则把 Python 字符串转换为字节串。这里的 `encode` 是字符串方法，不是分词器的 `encode` 方法。
26	`ids = list(text_bytes) # list of integers in range 0..255`	把字节串转换成整数列表，初始每项都在 0–255 之间。
29	`merges = {} # (int, int) -> int`	新建合并表，记录“两个旧编号 → 一个新编号”。
30	`vocab = {idx: bytes([idx]) for idx in range(256)} # int -> bytes`	建立初始词表：每个 0–255 的编号对应一个单字节串。

行号	原代码	逐行解释
31	`for i in range(num_merges):`	按预定次数循环；i 从 0 开始，每轮产生一个新 token。
33	`stats = get_stats(ids)`	对当前 ids 统计所有相邻对的频次。每轮都重新统计，因为序列已经改变。
35	`pair = max(stats, key=stats.get)`	按 stats 中的计数选最大的 pair。若并列，这段代码采用字典遍历中先遇到者。
37	`idx = 256 + i`	新编号从 256 起，随后依次为 257、258……；它也记录规则产生的先后顺序。
39	`ids = merge(ids, pair, idx)`	将当前序列中可从左到右配对的 pair 替换为 idx，并更新 ids。
41	`merges[pair] = idx`	把新规则写入合并表，供以后编码新文本时使用。
42	`vocab[idx] = vocab[pair[0]] + vocab[pair[1]]`	把两个旧 token 对应的字节串相接，得到新 token 的实际字节内容。这里的 + 是拼接字节串。
44	`if verbose:`	只有 verbose 为真时，才执行下一行打印。
45	`print(f"merge {i+1}/{num_merges}: {pair} -> {idx} ({vocab[idx]}) had {stats[pair]} occurrences")`	打印轮次、合并对、新编号、字节内容和相邻窗口计数；最后这个计数不一定等于实际替换次数。
48	`self.merges = merges # used in encode()`	把学到的合并表交给当前分词器，后续 encode 会读取它。
49	`self.vocab = vocab # used in decode()`	把完整词表交给当前分词器，后续 decode 会读取它。

这里的“训练”没有神经网络反向传播，只是反复统计与合并。代码也没有在相邻对耗尽时自动提前结束：如果文本太短而目标词表设得过大，stats 可能为空，max 会失败。因此小例子只设 259，而不是直接要求训练出几万个 token。实际实验应准备足够语料，并检查停止条件。

A.3.2 basic.py：decode 把编号还原成文字，51–55 行

minbpe/basic.py，第 51–55 行（仅列执行语句）

行号	原代码	逐行解释
51	`def decode(self, ids):`	定义解码方法，输入是一串 token ID。
53	`text_bytes = b"".join(self.vocab[idx] for idx in ids)`	依次按编号查词表，取出各 token 的字节内容，用空字节串连接成完整字节序列。
54	`text = text_bytes.decode("utf-8", errors="replace")`	将完整字节序列按 UTF-8 还原为文字；非法字节序列用替代字符表示。
55	`return text`	返回还原后的字符串。

必须先拼接字节，再解码成文字。原因是一个 token 可能只保存某个汉字 UTF-8 编码的一部分，单独解码它未必合法。对合法文本正常 encode 后再 decode，通常可以恢复原文；任意拼凑 token ID、截断序列或输入无效字节，则不保证仍是合法文字。未知 ID 查词表也会出错。

A.3.3 basic.py：encode 用固定规则处理新文本，57–74 行

minbpe/basic.py，第 57–74 行（仅列执行语句）

行号	原代码	逐行解释
57	`def encode(self, text):`	定义编码方法：输入普通字符串，返回 token ID 列表。
59	`text_bytes = text.encode("utf-8") # raw bytes`	先将文本转换为 UTF-8 字节串。
60	`ids = list(text_bytes) # list of integers in range 0..255`	再把每个字节转换为 0–255 的初始整数编号。
61	`while len(ids) >= 2:`	至少有两个编号时才可能合并；只有 0 或 1 个时直接结束循环。
63	`stats = get_stats(ids)`	列出当前序列中出现的相邻对；此处虽然也计算次数，但下一行不使用次数作决策。
64	`pair = min(stats, key=lambda p: self.merges.get(p, float("inf")))`	对每个相邻对 p 查已学合并编号，选编号最小者；没学过的 pair 记为正无穷，使其排在可用规则之后。
69	`if pair not in self.merges:`	若选中的相邻对不在合并表，说明当前所有相邻对都没有可用合并规则。
70	`break # nothing else can be merged anymore`	结束循环，不再继续合并。
72	`idx = self.merges[pair]`	读取这条既有规则对应的新 token 编号。
73	`ids = merge(ids, pair, idx)`	执行不重叠替换，得到下一轮的序列。这里不创建新规则。
74	`return ids`	返回最终 token ID 列表。

训练阶段按“当前出现最多”来创造规则；编码阶段按“已有规则中最早学到”来应用规则。例如假设已有 ab→256、bc→257，处理 bcbcab 时，即使 bc 出现 2 次、ab 只出现 1 次，也先使用编号较小的 ab 规则。这正是 max(stats, key=stats.get) 与 min(..., key=lambda ...) 的区别。不能把编码解释成“在每次用户输入里重新统计最常见对并训练”。

A.4 regex.py：为什么还要在 BPE 前预切分?

RegexTokenizer 先用正则表达式把文字分成若干块，然后在每一块内部独立做 BPE。正则表达式可以理解为一套按字符类型找片段的规则。它让字母、数字、标点、换行等先按预设模式分组；BPE 不能跨过这些分组边界随意合并。分组边界由具体模式决定，不等于简单按空格切词。

GPT-4 模式中的分支	通俗解释
'(?i:[sdmt]|ll|ve|re)	匹配若干带撇号的英文缩写后缀，并局部忽略大小写。
[^\r\n\p{L}\p{N}]?+\p{L}+	匹配连续字母，并允许前面附带一个符合条件的非字母数字字符；常见效果包括把前导空格与后面的词放在一块。
\p{N}{1,3}	把连续数字按每块 1–3 个数字匹配。
?[^\s\p{L}\p{N}]++[\r\n]*	匹配一段非空白、非字母、非数字字符，可含前导空格和末尾换行。
\s*[\r\n]	处理包含换行的空白片段。
\s+(?!\S) 与 \s+	处理其余符合条件的空白。具体由模式顺序与匹配语义决定。

这些规则不是让分词器理解语法或词义，而是设定允许合并的范围。中文字符也可属于 Unicode 字母类别；不能把“字母分支”仅理解为 a 到 z。regex.py 第 12 行导入的是第三方 regex 包并命名为 re，不是

Python 自带 re；这与模式中的 Unicode 属性写法有关。

A.4.1 regex.py：初始化预切分与特殊 token 状态，24–34 行

minbpe/regex.py，第 24–34 行（仅列执行语句）

行号	原代码	逐行解释
24	`def __init__(self, pattern=None):`	定义初始化方法，可传入自定义正则模式；不传时使用默认值。
30	`super().__init__()`	先完成公共 Tokenizer 的初始化。
31	`self.pattern = GPT4_SPLIT_PATTERN if pattern is None else pattern`	若 pattern 没传，就选 GPT4_SPLIT_PATTERN；否则使用调用者提供的模式。
32	`self.compiled_pattern = re.compile(self.pattern)`	把模式编译成可重复使用的正则对象。
33	`self.special_tokens = {}`	建立“特殊字符串 → 编号”的空表。
34	`self.inverse_special_tokens = {}`	建立“编号 → 特殊字符串”的空表，供反向恢复时使用。

A.4.2 regex.py：训练时共享统计，但不跨块合并，36–70 行

minbpe/regex.py，第 36–70 行（仅列执行语句）

行号	原代码	逐行解释
36	`def train(self, text, vocab_size, verbose=False):`	定义训练方法，输入训练文本、目标词表大小和打印开关。
37	`assert vocab_size >= 256`	要求至少保留 256 个单字节 token。
38	`num_merges = vocab_size - 256`	计算需要学习多少条新合并规则。
41	`text_chunks = re.findall(self.compiled_pattern, text)`	按编译后的正则模式找到全部文本块。
44	`ids = [list(ch.encode("utf-8")) for ch in text_chunks]`	每个块先 UTF-8 编码再转列表，得到“列表的列表”；块边界仍然保留。
47	`merges = {} # (int, int) -> int`	建立本次训练的新合并表。
48	`vocab = {idx: bytes([idx]) for idx in range(256)} # idx -> bytes`	建立初始 256 项字节词表。
49	`for i in range(num_merges):`	每轮产生一个新 token。
51	`stats = {}`	每一轮先清空总统计表。
52	`for chunk_ids in ids:`	逐个取出文本块的编号列表。
54	`get_stats(chunk_ids, stats)`	累计当前块内部的相邻对；不会把前块末尾与后块开头算成一对。
56	`pair = max(stats, key=stats.get)`	在各块累加后的统计中选频次最高的 pair。
58	`idx = 256 + i`	新编号按 256、257……依次递增。
60	`ids = [merge(chunk_ids, pair, idx) for chunk_ids in ids]`	对每块分别执行 merge，保留块边界并替换整个 ids 列表。
62	`merges[pair] = idx`	记录两个旧编号合成新编号的关系。
63	`vocab[idx] = vocab[pair[0]] + vocab[pair[1]]`	拼接旧 token 的字节内容，生成新词表项。
65	`if verbose:`	verbose 为真时才打印。

行号	原代码	逐行解释
66	print(f"merge {i+1}/{num_merges}: {pair} -> {idx} ({vocab[idx]}) had {stats[pair]} occurrences")	打印合并细节；次数是全体块内部相邻窗口的总数。
69	self.merges = merges # used in encode()	保存合并规则，供以后编码。
70	self.vocab = vocab # used in decode()	保存词表，供以后解码。

这里要同时记住两件事：规则由所有块共同贡献的频次决定，因此不是为每个单词单独训练一套规则；合并只在各块内部发生，因此也不是先把所有块重新拼起来再训练。与 `BasicTokenizer` 一样，这段最小实现没有“没有相邻对时提前停止”的保护。

A.4.3 regex.py：_encode_chunk 只编码一个字节块，92–109 行

minbpe/regex.py，第 92–109 行（仅列执行语句）

行号	原代码	逐行解释
92	def _encode_chunk(self, text_bytes):	定义内部方法，输入已经转为字节串的一个文本块；名字前的下划线表示通常供类内部使用。
95	ids = list(text_bytes)	把字节串转成整数列表。这里不再执行 UTF-8 编码，因为输入已经是 bytes。
96	while len(ids) >= 2:	当至少还有两个编号时继续尝试合并。
98	stats = get_stats(ids)	获取当前块中出现的相邻对。
99	pair = min(stats, key=lambda p: self.merges.get(p, float("inf")))	查各相邻对的既有合并编号，优先选择编号最小者；未知对记为正无穷。
104	if pair not in self.merges:	若候选不在合并表，说明没有可继续使用的规则。
105	break # nothing else can be merged anymore	结束本块的合并循环。
107	idx = self.merges[pair]	读取该规则对应的目标 token ID。
108	ids = merge(ids, pair, idx)	在当前块中做不重叠替换。
109	return ids	返回这个块最终的 token ID 列表。

A.4.4 regex.py：encode_ordinary 依次编码普通文本块，111–121 行

minbpe/regex.py，第 111–121 行（仅列执行语句）

行号	原代码	逐行解释
111	def encode_ordinary(self, text):	定义普通文本编码入口，不把任何字符串当作特殊 token。
114	text_chunks = re.findall(self.compiled_pattern, text)	取得所有正则文本块。
116	ids = []	建立最终编号列表。
117	for chunk in text_chunks:	按原文顺序遍历文本块。
118	chunk_bytes = chunk.encode("utf-8") # raw bytes	把当前块转换成 UTF-8 字节串。

行号	原代码	逐行解释
119	`chunk_ids = self._encode_chunk(chunk_bytes)`	交给 `_encode_chunk` 做块内 BPE。这里通过 `self` 调用，子类改写的方法也会生效。
120	`ids.extend(chunk_ids)`	把本块所有编号逐个接到总列表末尾。若用 `append`，会错误地形成嵌套列表。
121	`return ids`	返回整段普通文本的编号序列。

整个顺序是：字符串 → 正则分块 → 每块转 UTF-8 → 每块 BPE → 按原顺序连接 token ID。这里连接的是已经完成编码的编号列表，不会在连接后再跨块进行 BPE。

A.4.5 regex.py：特殊 token 是另行登记的控制标记

某些系统会把特定字符串登记成一个特殊 token，例如 <|endoftext|>。它的身份来自额外登记，不是因为 BPE 碰巧学出了相同文字。原样输入这一串字符时，究竟按普通文字拆开、按一个特殊编号处理，还是报错，取决于 allowed_special。这里只解释仓库接口，不把这些标记当成本报告应执行的指令。

minbpe/regex.py，第 72–76 行（仅列执行语句）

行号	原代码	逐行解释
72	`def register_special_tokens(self, special_tokens):`	登记调用者提供的特殊 token 字典。
75	`self.special_tokens = special_tokens`	保存正向表；这不是修改普通 BPE 合并表。
76	`self.inverse_special_tokens = {v: k for k, v in special_tokens.items()}`	交换键和值，建立“特殊编号 → 特殊字符串”的反向表。

allowed_special	这份实现的行为
"all"	所有已登记特殊字符串都可以按特殊 token 编码。
"none"	不启用特殊处理；即使文本长得像标记，也按普通文本编码。
"none_raise"（默认）	如果文本含任意已登记特殊字符串，断言失败；否则按普通文本编码。
一个 set，例如 {"<|endoftext|>"}	只启用集合中且已登记的特殊 token；其他标记在这份实现中按普通文本处理。
其他值	抛出 ValueError，表示接口参数不支持。

minbpe/regex.py，第 123–164 行（仅列执行语句）

行号	原代码	逐行解释
123	`def encode(self, text, allowed_special="none_raise"):`	定义对外编码入口，默认策略为 none_raise。
132	`special = None`	先把待启用的特殊 token 表置为 None。
133	`if allowed_special == "all":`	判断是否要求启用所有特殊 token。
134	`special = self.special_tokens`	直接使用全部已登记特殊 token。
135	`elif allowed_special == "none":`	判断是否要求把一切当作普通文本。
136	`special = {}`	使用空表，不启用任何特殊 token。
137	`elif allowed_special == "none_raise":`	判断是否采用默认的拒绝标记策略。
138	`special = {}`	仍使用空表，后续走普通编码。
139	`assert all(token not in text for token in self.special_tokens)`	检查所有已登记特殊字符串都没有出现在输入中；只要出现一个，断言失败。

行号	原代码	逐行解释
140	`elif isinstance(allowed_special, set):`	判断参数是否为 Python 集合 `set`。
141	`special = {k: v for k, v in self.special_tokens.items() if k in allowed_special}`	从已登记表中筛出集合允许的条目，生成本次使用的特殊表。
142	`else:`	其他参数类型或值进入这个分支。
143	`raise ValueError(f"allowed_special={allowed_special} not understood")`	抛出参数错误，并在信息中显示不被理解的值。
144	`if not special:`	若启用表为空，就无需做特殊文本切分。
146	`return self.encode_ordinary(text)`	直接返回 `encode_ordinary` 的结果，结束当前函数。
152	`special_pattern = "(" + "|".join(re.escape(k) for k in special) + ")"`	先转义各特殊字符串，避免其符号被当作正则语法；用 | 表示“任一标记”，再加括号保留匹配内容。
153	`special_chunks = re.split(special_pattern, text)`	按这个模式切开输入，得到普通片段和特殊片段交替组成的列表。
156	`ids = []`	建立最终编号列表。
157	`for part in special_chunks:`	按原顺序逐个处理片段。
158	`if part in special:`	若该片段正好是启用表中的特殊字符串，走特殊分支。
160	`ids.append(special[part])`	把它对应的单个特殊 token ID 加入列表，不对它做普通 BPE。
161	`else:`	否则按普通片段处理。
163	`ids.extend(self.encode_ordinary(part))`	调用 `encode_ordinary`，并把返回的各编号接到总列表末尾。
164	`return ids`	返回最终编号序列。

对一个空的普通片段，`encode_ordinary` 会返回空列表，因此 `re.split` 产生的首尾空片段不会额外制造 token。默认 `none_raise` 在这份代码里用 `assert` 实现；报告准确写“触发断言”即可，不需要把它描述成 `ValueError`。

A.4.6 regex.py：普通类如何解码特殊编号，78–90 行

`minbpe/regex.py`，第 78–90 行（仅列执行语句）

行号	原代码	逐行解释
78	`def decode(self, ids):`	定义 `RegexTokenizer` 的解码方法。
80	`part_bytes = []`	准备收集每个编号对应的字节片段。
81	`for idx in ids:`	按顺序遍历输入编号。
82	`if idx in self.vocab:`	先判断编号是否在普通 BPE 词表中。
83	`part_bytes.append(self.vocab[idx])`	如果是，加入普通词表对应的字节串。
84	`elif idx in self.inverse_special_tokens:`	否则判断它是否是已登记的特殊编号。
85	`part_bytes.append(self.inverse_special_tokens[idx].encode("utf-8"))`	若是特殊编号，把对应特殊字符串转为 UTF-8 字节并加入。
86	`else:`	两种表都查不到时进入错误分支。
87	`raise ValueError(f"invalid token id: {idx}")`	抛出 `ValueError`，指出未知编号。
88	`text_bytes = b"".join(part_bytes)`	拼接所有字节片段。

行号	原代码	逐行解释
89	`text = text_bytes.decode("utf-8", errors="replace")`	对完整字节序列做 UTF-8 解码，非法序列用替代字符处理。
90	`return text`	返回文本。

这段代码说明“支持特殊 token 解码”需要专门分支。后面 GPT4Tokenizer 改写了 decode，不能仅因它继承 RegexTokenizer，就推断它仍完整保留了这段特殊编号处理。这个细节会影响往返测试。

A.5 gpt4.py：它复现的是已有 cl100k_base 分词规则

MinBPE 中名为 GPT4Tokenizer 的类读取 tiktoken 已有的 cl100k_base 编码表，再把规则接到 RegexTokenizer 流程上。本项目研究这一固定编码的分词复现、规则恢复与字节编号映射；它不等同于训练 GPT-4 模型，也不代表所有后续 GPT 系列模型共享同一分词器。

调用位置	实际发生的事
GPT4Tokenizer 初始化	读取预训练编码表，恢复合并关系，准备字节编号映射和特殊 token 表。
继承的 RegexTokenizer.encode	根据 allowed_special 处理特殊片段；普通片段交给 encode_ordinary。
继承的 encode_ordinary	做 GPT-4 正则预切分，然后调用 self._encode_chunk。
GPT4Tokenizer._encode_chunk	先把原始字节换成官方单字节 token 编号，再调用父类的 BPE 编码。
GPT4Tokenizer.decode	先查词表拼接内部字节表示，再把单字节编号映射回原始字节，最后 UTF-8 解码。

A.5.1 gpt4.py：初始化预训练规则，60–79 行

minbpe/gpt4.py，第 60–79 行（仅列执行语句）

行号	原代码	逐行解释
60	`def __init__(self):`	创建 GPT4Tokenizer 对象时执行此初始化方法。
61	`super().__init__(pattern=GPT4_SPLIT_PATTERN)`	调用 RegexTokenizer 初始化，并明确使用 GPT4_SPLIT_PATTERN。
63	`enc = tiktoken.get_encoding("cl100k_base")`	从 tiktoken 获取 cl100k_base 编码器。这一步不是训练模型。
64	`mergeable_ranks = enc._mergeable_ranks`	读取其“字节串 → 合并等级 / 编号”表。属性名以单下划线开头，属于实现细节，版本变化时需核对。
66	`self.merges = recover_merges(mergeable_ranks)`	调用 recover_merges，生成 MinBPE 使用的“两个 token ID → 新 ID”表。
68	`vocab = {idx: bytes([idx]) for idx in range(256)}`	先把 0–255 编号各记为同数值单字节；注意这里暂时是内部编号表示，并非都等于实际原始字节。
69	`for (p0, p1), idx in self.merges.items():`	按合并表顺序遍历两个子 token 与新编号。
70	`vocab[idx] = vocab[p0] + vocab[p1]`	把两个子项的内部字节表示拼接，建立新 token 项。
71	`self.vocab = vocab`	把构造好的内部词表存到对象。

行号	原代码	逐行解释
76	`self.byte_shuffle = {i: mergeable_ranks[bytes([i])] for i in range(256)}`	为每个原始字节 i 查官方单字节 token 编号，建立正向重排表。
77	`self.inverse_byte_shuffle = {v: k for k, v in self.byte_shuffle.items()}`	交换键和值，建立“官方单字节编号 → 原始字节”的逆向映射。
79	`self.register_special_tokens(GPT4_SPECIAL_TOKENS)`	调用父类提供的登记方法，保存 GPT4_SPECIAL_TOKENS 及其反向表。

初学时可以把 byte_shuffle 理解为“两套编号体系之间的换号表”。同一个原始字节，在 BasicTokenizer 中初始编号直接取它的数值，在 cl100k_base 中则要查官方编号。重排并没有改变输入文字的含义；它只是让后续合并表看到自己预期的编号。构建出来的 self.vocab 暂存的是这套内部表示，因此解码时还必须反向换回来。

A.5.2 gpt4.py：编码前先换号，81–85 行

minbpe/gpt4.py，第 81–85 行（仅列执行语句）

行号	原代码	逐行解释
81	`def _encode_chunk(self, text_bytes):`	改写父类的单块编码方法，输入仍是一个 UTF-8 字节串。
83	`text_bytes = bytes(self.byte_shuffle[b] for b in text_bytes)`	逐字节查询 byte_shuffle，得到官方单字节编号，并用 bytes 容器包装这些 0–255 的数。
84	`ids = super()._encode_chunk(text_bytes)`	调用 RegexTokenizer._encode_chunk 执行已学规则的 BPE。super() 避免再次调用自己而无限递归。
85	`return ids`	返回该块的最终编号列表。

为什么不用在 encode_ordinary 里再写一遍 GPT-4 专用流程？因为它调用的是 self._encode_chunk。当 self 是 GPT4Tokenizer 对象时，Python 会使用这里改写的版本。于是普通的正则分块流程得到复用，而特殊的换号步骤只写在这一小段里。

A.5.3 gpt4.py：解码时换回原始字节，87–92 行

minbpe/gpt4.py，第 87–92 行（仅列执行语句）

行号	原代码	逐行解释
87	`def decode(self, ids):`	定义 GPT4Tokenizer 自己的解码方法，覆盖父类版本。
89	`text_bytes = b"".join(self.vocab[idx] for idx in ids)`	按普通词表查各编号，并把内部字节表示拼接起来。这里没有特殊 token 分支。
90	`text_bytes = bytes(self.inverse_byte_shuffle[b] for b in text_bytes)`	逐个查询 inverse_byte_shuffle，将内部编号表示变回真实原始字节。
91	`text = text_bytes.decode("utf-8", errors="replace")`	按 UTF-8 解码为字符串；无效字节用替代字符处理。
92	`return text`	返回文本。

这个固定提交有一个应如实写明的限制：GPT4Tokenizer.decode 直接读取 self.vocab，没有像 RegexTokenizer.decode 那样处理 inverse_special_tokens。其初始化也没有把特殊编号放进普通 self.vocab。因此若将 encode(..., allowed_special="all") 得到的特殊 ID 交给这个 decode，会在查表处遇到 KeyError。普通文本的往返编码和包含特殊 ID 的往返编码，应分开说明；不能声称该版本在所有特殊 token 情形下都完整等价于 tiktoken。

minbpe/gpt4.py，第 94–96 行（仅列执行语句）

行号	原代码	逐行解释
95	`def train(self, text, vocab_size, verbose=False):`	显式定义 train 方法以覆盖继承来的训练接口。
96	`raise NotImplementedError`	调用时直接抛出 NotImplementedError，不会重新学习词表。

A.6 进阶附录：recover_merges 如何从现成词表找回合并关系

前面已足以解释使用流程。下面两段用于回答更深入的“为什么 GPT4Tokenizer 的初始化可以得到 merges”。tiktoken 给出的是“一个完整字节串对应哪个 rank”，MinBPE 想要的是“哪两个旧 token 合成这个 token”。恢复函数会对每个多字节 token，只应用比它更早的规则，把它还原到即将完成最后一次合并的两个子块。这不是用新训练语料重新统计频次。源码注释把它称为一个小型 BPE 过程，报告应把其实际含义说清楚。

minbpe/gpt4.py，第 29–46 行（仅列执行语句）

行号	原代码	逐行解释
29	`def recover_merges(mergeable_ranks):`	定义恢复函数，输入为完整字节串到 rank 的已有映射。
35	`merges = {}`	准备保存恢复出的“两个编号 → 新编号”映射。
36	`for token, rank in mergeable_ranks.items():`	遍历已有映射中的字节串 token 及其 rank。
37	`if len(token) == 1:`	判断该 token 是否只包含一个字节。
38	`continue # skip raw bytes`	单字节是起点，没有两个子 token 的合并关系，直接跳过。
39	`pair = tuple(bpe(mergeable_ranks, token, max_rank=rank))`	调用辅助 bpe，只允许使用 rank 小于当前 token 的规则；把返回列表转成元组。

行号	原代码	逐行解释
40	`assert len(pair) == 2`	正常情况下应恰好剩两个子块；否则断言失败。
42	`ix0 = mergeable_ranks[pair[0]]`	查第一个子块的 rank / 编号。
43	`ix1 = mergeable_ranks[pair[1]]`	查第二个子块的 rank / 编号。
44	`merges[(ix0, ix1)] = rank`	记录这两个子编号合并后得到当前 rank。
46	`return merges`	返回恢复完成的合并表。

例如完整 token 表里有 ab、abab，且 ab 的规则早于 abab。恢复 abab 时，先允许 a+b→ab，但禁止使用 abab 自己的规则，于是停在 [ab,ab]，便知道 abab 是由两个 ab 合成的。这是理解 max_rank 参数最直接的办法。这里为了直观使用文本片段表示，实际代码处理的是 bytes。

A.6.1 进阶附录：辅助 bpe 的逐行过程，11–26 行

minbpe/gpt4.py，第 11–26 行（仅列执行语句）

行号	原代码	逐行解释
11	`def bpe(mergeable_ranks, token, max_rank):`	定义辅助函数，输入已有 rank 表、一个待拆解字节串，以及允许合并等级的上界。
13	`    parts = [bytes([b]) for b in token]`	先把 token 拆成多个单字节串；此处 parts 是 bytes 片段的列表，不是整数 ID 列表。
14	`    while True:`	进入循环，直到没有合适的合并可以执行。
15	`        min_idx = None`	本轮暂时还没选中相邻位置。
16	`        min_rank = None`	本轮暂时还没找到最小 rank。
17	`        for i, pair in enumerate(zip(parts[:-1], parts[1:])):`	zip 产生相邻片段对；enumerate 同时给出每一对左端的位置 i。
18	`            rank = mergeable_ranks.get(pair[0] + pair[1])`	把两个片段的 bytes 拼接，在已有词表中查它的 rank；没有则得到 None。
19	`            if rank is not None and (min_rank is None or rank < min_rank):`	只有词表存在该合并，且它比目前候选更早或还没有候选，才更新最佳选择。
20	`                min_idx = i`	记录当前最佳相邻对的左端位置。
21	`                min_rank = rank`	记录当前最小 rank。
22	`        if min_rank is None or (max_rank is not None and min_rank >= max_rank):`	若没有候选，或候选等级已达到当前 token 的 max_rank 上界，就停止。比较用 >=，因此只允许严格更小的 rank。
23	`            break`	结束循环，保留尚未合并的片段。
24	`        assert min_idx is not None`	正常继续合并时必须已找到位置；该断言检查内部逻辑。
25	`        parts = parts[:min_idx] + [parts[min_idx] + parts[min_idx + 1]] + parts[min_idx + 2:]`	保留选中位置之前的片段，把选中的两块拼成一块，再接上其后的片段；这一轮只合并这个位置。
26	`    return parts`	返回剩余字节片段列表。recover_merges 希望这里返回两个子块。

不要把两个辅助函数混淆：base.merge 接收整数编号，针对已经选定的一种 pair 从左向右替换多个不重叠出现；gpt4.bpe 接收字节片段，在每轮重新扫描候选后只合并选中的一个位置，并受到 max_rank 限制。两者服务于不同阶段。

MinBPE 固定提交：`base.py`，公共统计、合并和词表结构。
https://github.com/karpathy/minbpe/blob/1acefe89412b20245db5a22d2a02001e547dc602/minbpe/base.py#L13-L95

MinBPE 固定提交：`basic.py`，基础字节级 BPE 训练、编码与解码。
https://github.com/karpathy/minbpe/blob/1acefe89412b20245db5a22d2a02001e547dc602/minbpe/basic.py#L15-L74

MinBPE 固定提交：`regex.py`，预切分、普通编码和特殊 `token` 处理。
https://github.com/karpathy/minbpe/blob/1acefe89412b20245db5a22d2a02001e547dc602/minbpe/regex.py#L12-L164

MinBPE 固定提交：`gpt4.py`，`cl100k_base` 包装、合并恢复、字节编号重排与接口限制。
https://github.com/karpathy/minbpe/blob/1acefe89412b20245db5a22d2a02001e547dc602/minbpe/gpt4.py#L11-L96